

LAPORAN TUGAS PRAKTIKUM 2

Praproses Data – House Prices: Advanced Regression Techniques

Nama: Muhammad Rafie Safaraz Barus | NRP: 5054251014

Mata Kuliah Data Mining

1. Pendahuluan

Praktikum ini bertujuan menyiapkan dataset agar siap dipakai untuk analisis atau model machine learning. Dataset yang digunakan adalah `train.csv` dari kompetisi Kaggle *House Prices – Advanced Regression Techniques*, berisi data 1460 rumah dengan 81 kolom, misalnya ukuran tanah, luas bangunan, tahun dibangun, kondisi rumah, dan harga jual (`SalePrice`) sebagai target. Tahapan yang dilakukan: import data, pembersihan data (nilai hilang, duplikat, data tidak konsisten), penanganan outlier, transformasi (standarisasi dan one-hot encoding), serta reduksi dimensi (analisis korelasi dan PCA). Semua proses dikerjakan di Python menggunakan `pandas`, `matplotlib`, `seaborn`, dan `scikit-learn`.

2. Import dan Pemahaman Data

Dataset dibaca menggunakan `pd.read_csv()`, kemudian strukturnya dilihat dengan `.head()`, `.shape`, dan `.info()`. Hasilnya, dataset berukuran **1460 baris × 81 kolom** yang terdiri dari 38 kolom numerik (35 integer dan 3 float) dan 43 kolom kategorikal. Dari `.info()` terlihat beberapa kolom memiliki jumlah *non-null* jauh di bawah 1460, sehingga perlu dicek nilai hilangnya.


3. Pembersihan Data

3.1 Pengecekan Nilai Hilang

Jumlah nilai hilang pada setiap kolom dihitung dengan `df.isnull().sum()`. Terdapat **19 kolom** yang memiliki nilai hilang (Gambar 1). Lima kolom memiliki nilai hilang lebih dari 50% sehingga dihapus, karena kolom tersebut lebih banyak kosong daripada terisi dan kalau diisi hasilnya hanya tebakan. Selain itu, kolom `Id` juga dihapus karena hanya nomor urut. Setelah langkah ini dataset menjadi **1460 × 75**.

Kolom	Jumlah Hilang	Persentase	Keterangan
PoolQC	1453	99,52%	Kualitas kolam renang
MiscFeature	1406	96,30%	Fitur tambahan lain
Alley	1369	93,77%	Jenis akses gang
Fence	1179	80,75%	Kualitas pagar
MasVnrType	872	59,73%	Jenis pelapis dinding

Tabel 1. Kolom yang dihapus karena nilai hilang > 50%



Gambar 1. Persentase nilai hilang per kolom (merah = di atas 50%, dihapus)

3.2 Penanganan Nilai Hilang yang Tersisa

Berdasarkan data_description.txt, nilai NA pada kolom garasi, basement, dan perapian berarti rumah tersebut *tidak memiliki* fasilitas itu. Hal ini terbukti dari jumlahnya yang sama, misalnya 690 data FireplaceQu yang hilang sama persis dengan 690 rumah yang Fireplaces = 0, dan 81 data garasi yang hilang sama dengan 81 rumah yang GarageArea = 0. Jadi nilai hilang tersebut diisi sebagai kategori baru, bukan dibuang. Strategi lengkapnya ada pada Tabel 2. Setelah proses ini, jumlah nilai hilang pada dataset menjadi 0.

Kolom	Jumlah Hilang	Penanganan
FireplaceQu	690	Diisi 'None' (tidak ada perapian)
GarageType, GarageFinish, GarageQual, GarageCond	81	Diisi 'None' (tidak ada garasi)
BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2	37–38	Diisi 'None' (tidak ada basement)
Electrical	1	Diisi modus (SBrkr)
GarageYrBlt	81	Diisi dengan nilai YearBuilt
LotFrontage	259	Diisi median (69)
MasVnrArea	8	Diisi median (0)

Tabel 2. Strategi pengisian nilai hilang

Median dipilih untuk kolom numerik karena tidak terpengaruh outlier. Median MasVnrArea bernilai 0 karena sebagian besar rumah tidak memiliki pelapis dinding, dan pada 8 data tersebut jenis pelapisnya (MasVnrType) juga kosong.

3.3 Duplikat dan Data Tidak Konsisten


Pengecekan dengan `df.duplicated()` menunjukkan tidak ada data duplikat. Pengecekan logika tahun juga tidak menemukan kesalahan (tidak ada rumah yang direnovasi sebelum dibangun maupun dibangun setelah terjual). Satu ketidakkonsistenan yang ditemukan adalah kolom `MSSubClass` yang bertipe angka, padahal isinya kode tipe bangunan (20, 60, 70, 190, dst.). Angka tersebut tidak punya arti besar-kecil, sehingga tipenya diubah menjadi kategorikal (string) agar ikut di-*encode*.

4. Deteksi dan Penanganan Outlier


Outlier dideteksi menggunakan boxplot pada 35 atribut numerik (Gambar 2) dan dihitung dengan metode IQR, yaitu nilai di bawah $Q1 - 1,5 \times IQR$ atau di atas $Q3 + 1,5 \times IQR$. Hasilnya, hampir semua atribut memiliki outlier dan terdapat **872 dari 1460 baris ($\pm 60\%$)** yang memiliki minimal satu outlier. Jika semua baris tersebut dihapus, lebih dari setengah data akan hilang, sehingga penghapusan massal tidak dilakukan.

Keputusan penanganan outlier dibagi menjadi tiga:

1. **Dihapus:** 2 rumah dengan `GrLivArea > 4000` tetapi `SalePrice < 300.000` (indeks 523 dan 1298). Rumah ini sangat besar tetapi harganya murah dan berstatus penjualan *Partial*, sehingga menyimpang jauh dari pola data lainnya (Gambar 3). Karena jumlahnya hanya 2, menghapusnya tidak mengurangi data secara berarti.
2. **Disesuaikan (capping):** 12 atribut luas yang kontinu. Nilai di luar batas IQR diganti menjadi nilai batas bawah/atas menggunakan `clip()`. Cara ini dipilih agar nilai ekstrem tidak mendominasi, tetapi barisnya tetap ada. Jumlah nilai yang disesuaikan ada pada Tabel 3.
3. **Dibiarkan:** atribut diskrit (`OverallCond`, `BedroomAbvGr`, `KitchenAbvGr`, dll.), atribut tahun, dan atribut yang mayoritas bernilai 0 (`PoolArea`, `ScreenPorch`, `EnclosedPorch`, `MiscVal`, dll.). Outlier pada atribut ini adalah nilai yang wajar, misalnya rumah yang memiliki kolam renang. Selain itu, IQR atribut yang mayoritas 0 juga bernilai 0, sehingga jika di-capping semua nilainya akan berubah menjadi 0 dan informasinya hilang. Target `SalePrice` juga tidak diubah.




Gambar 2. Boxplot seluruh atribut numerik sebelum penanganan outlier



Gambar 3. Scatter plot GrLivArea terhadap SalePrice (merah = anomali yang dihapus)

Atribut	Nilai di-capping	Atribut	Nilai di-capping
LotFrontage	104	1stFlrSF	18
LotArea	66	2ndFlrSF	2
MasVnrArea	97	GrLivArea	29
BsmtFinSF1	5	GarageArea	20
BsmtUnfSF	29	WoodDeckSF	32
TotalBsmtSF	59	OpenPorchSF	75

Tabel 3. Jumlah nilai yang disesuaikan pada setiap atribut (total 536 nilai)




Gambar 4. Perbandingan boxplot sebelum dan sesudah capping

Gambar 4 menunjukkan bahwa setelah capping, titik-titik outlier pada 12 atribut tersebut sudah tidak ada, sedangkan median dan kotak IQR-nya tidak berubah. Jumlah data setelah tahap ini adalah **1458 baris**.

5. Transformasi Data

5.1 Standarisasi

Skala antar atribut numerik sangat berbeda, contohnya LotArea bernilai ribuan sedangkan OverallQual hanya 1–10. Oleh karena itu, 35 atribut numerik distandarisasi menggunakan StandardScaler (z-score) dengan rumus $z = (x - \text{mean}) / \text{std}$, sehingga setiap atribut memiliki mean 0 dan standar deviasi 1. Standarisasi dipilih (bukan min-max) karena tahap berikutnya menggunakan PCA yang bekerja berdasarkan varians, sehingga semua atribut perlu memiliki varians yang setara. SalePrice tidak distandarisasi karena merupakan target. Hasilnya terlihat pada Gambar 5, di mana setelah standarisasi semua atribut berada di sekitar 0 dengan rentang yang sebanding.



Gambar 5. Contoh lima atribut sebelum dan sesudah standarisasi


5.2 One-Hot Encoding

Sebanyak **39 atribut kategorikal** (termasuk MSSubClass dan kategori 'None' dari tahap sebelumnya) diubah menggunakan `pd.get_dummies()`. Setiap kategori menjadi kolom biner baru yang bernilai 1 jika data termasuk kategori tersebut dan 0 jika tidak, misalnya `GarageType_Attchd` atau `GarageType_None`. One-hot encoding digunakan karena model machine learning hanya bisa menerima input angka, dan cara ini tidak memberi urutan palsu pada kategori. Proses ini menghasilkan 259 kolom biner, sehingga jumlah kolom bertambah dari 75 menjadi **295**.

6. Reduksi Dimensi

6.1 Analisis Korelasi

Korelasi Pearson antar atribut numerik dihitung dan divisualisasikan dalam heatmap (Gambar 6). Pasangan atribut dengan korelasi $|r| > 0,8$ dianggap redundan karena membawa informasi yang hampir sama. Dari setiap pasangan, atribut yang dibuang adalah yang korelasinya terhadap `SalePrice` lebih kecil (Tabel 4). Hasilnya, 4 atribut dihapus dan jumlah kolom menjadi **291**.



Gambar 6. Heatmap korelasi atribut numerik


Atribut 1	Atribut 2	Korelasi	r(1, SalePrice)	r(2, SalePrice)	Dihapus
GarageCars	GarageArea	0,894	0,641	0,633	GarageArea
YearBuilt	GarageYrBlt	0,845	0,524	0,509	GarageYrBlt
GrLivArea	TotRmsAbvGrd	0,834	0,712	0,538	TotRmsAbvGrd
TotalBsmtSF	1stFlrSF	0,805	0,640	0,624	1stFlrSF

Tabel 4. Pasangan atribut dengan korelasi > 0,8


Hasil ini masuk akal secara logika: jumlah mobil yang muat di garasi tentu berkaitan dengan luas garasi, dan jumlah ruangan berkaitan dengan luas bangunan. Dari heatmap juga terlihat atribut yang paling berkorelasi dengan SalePrice adalah OverallQual dan GrLivArea.

6.2 Principal Component Analysis (PCA)

PCA diterapkan pada seluruh 290 fitur (semua kolom kecuali SalePrice). Jumlah komponen dipilih berdasarkan grafik *cumulative explained variance* (Gambar 7), yaitu jumlah komponen minimum yang dapat mempertahankan 95% varians data. Hasilnya dibutuhkan **77 komponen**, sehingga dimensi data berkurang dari 290 menjadi 77 ($\pm 73\%$ lebih sedikit) dan informasi yang hilang hanya sekitar 5%. Komponen pertama (PC1) menjelaskan 15,4% varians dan PC2 menjelaskan 7,2% varians.



Gambar 7. Cumulative explained variance PCA (garis merah = 95%)



Gambar 8. Sebaran data pada PC1 dan PC2, diwarnai berdasarkan SalePrice

Pada Gambar 8 terlihat bahwa semakin besar nilai PC1, harga rumah cenderung semakin tinggi (warna makin gelap). Korelasi PC1 dengan SalePrice sebesar 0,86, artinya PC1 menangkap banyak informasi yang berhubungan dengan harga. Atribut yang paling berpengaruh pada PC1 adalah OverallQual, GarageCars, YearBuilt, dan GrLivArea, yaitu atribut yang menggambarkan kualitas, usia, dan luas rumah.

7. Ringkasan Dataset Akhir

Tahap	Proses	Ukuran Data
Data awal	Import <code>train.csv</code>	1460×81
Hapus kolom	5 kolom dengan nilai hilang $> 50\%$ dan <code>Id</code>	1460×75
Nilai hilang	Diisi 'None', modus, median, dan <code>YearBuilt</code>	1460×75
Data tidak konsisten	<code>MSSubClass</code> diubah menjadi kategorikal	1460×75
Outlier	2 baris anomali dihapus, 12 atribut di-capping	1458×75
Standarisasi	35 atribut numerik (mean 0, std 1)	1458×75
One-hot encoding	39 atribut kategorikal $\rightarrow$ 259 kolom biner	1458×295
Korelasi	4 atribut redundan dihapus	1458×291
PCA	290 fitur $\rightarrow$ 77 komponen (95% varians)	1458×77

Tabel 5. Ringkasan setiap tahap praproses

Dataset akhir yang disimpan ke file CSV berukuran **1458 baris $\times$ 291 kolom**, terdiri dari 31 atribut numerik yang sudah distandarisasi, 259 kolom hasil one-hot encoding, dan 1 kolom target `SalePrice`. Dataset ini sudah tidak memiliki nilai hilang, outlier sudah ditangani, dan semua kolomnya bertipe angka. Dataset yang disimpan adalah dataset sebelum PCA agar arti tiap kolom masih bisa dibaca. Jika ingin fitur yang lebih ringkas, hasil PCA 77 komponen dapat langsung dipakai sebagai input model.

8. Kesimpulan

1. Kolom dengan nilai hilang lebih dari 50% (`PoolQC`, `MiscFeature`, `Alley`, `Fence`, `MasVnrType`) dihapus. Nilai hilang lainnya sebagian besar berarti "tidak ada fasilitas", sehingga diisi kategori 'None', dan sisanya diisi median, modus, atau `YearBuilt`.
2. Outlier tidak dihapus semuanya karena akan menghilangkan $\pm 60\%$ data. Hanya 2 data anomali yang dihapus, 12 atribut luas di-capping dengan batas IQR, dan outlier yang merupakan nilai wajar dibiarkan.
3. Atribut numerik distandarisasi dengan `StandardScaler` dan atribut kategorikal di-encode dengan one-hot encoding, sehingga semua data berbentuk angka dengan skala yang sebanding.
4. Analisis korelasi menghapus 4 atribut redundan, dan PCA mampu meringkas 290 fitur menjadi 77 komponen dengan tetap mempertahankan 95% varians.