

Laporan Analisis — Eksplorasi Data Kandungan Gizi Makanan Indonesia

Nama: <Nama Lengkap> · NRP: <NRP> · Data Mining — Tugas Praktikum 1 · Sumber: nilaigizi.com (diakses 13 September 2026)

1. Deskripsi Dataset

Data di-scrape dari **nilaigizi.com** memakai `requests` dan `BeautifulSoup`: 1.850 halaman detail (dengan pengecekan `robots.txt`, jeda 0,5 detik; 50 halaman sudah dihapus) disimpan mentah ke `nilaigizi_raw.jsonl`. Hasilnya **1.800 baris x 40 kolom** (8 atribut informasi dan 32 zat gizi). Bahan mentah berasal dari TKPI 2018 Kemenkes (per 100 g), sedangkan produk kemasan/restoran berasal dari kontribusi pengguna (per sajian), sehingga zat gizi utama dikonversi ke **per 100 g**.

- **Nominal:** `id`, `nama`, `jenis_sumber` (bahan alami 65,8%, produk industri 20,3%, merek/restoran 11,7%, buatan sendiri 2,2%), `produsen` (185 kategori), `satuan_saji` (g/ml).
- **Ordinal (turunan):** `kategori_energi` = Sangat rendah < Rendah < Sedang < Tinggi (batas kepadatan energi 0,6 / 1,5 / 4 kkal/g).
- **Numerik diskrit:** `sajian_per_kemasan`, `bdd_persen`. **Numerik kontinu (rasio):** `takaran_saji` dan seluruh zat gizi (energi, protein, lemak, karbohidrat, serat, gula, natrium, vitamin, mineral).

2. Statistik Deskriptif


Per 100 g	n	Rata-rata	Median	Modus	Std	Min	Maks	Jenis sumber	Jumlah	%
Energi (kkal)	1,717	228.6	178.4	0.0	173.2	0.0	902.0	Bahan alami	1,184	65.8%
Protein (g)	1,717	9.1	5.4	0.0	10.4	0.0	80.0	Produk industri	366	20.3%
Lemak (g)	1,717	9.0	3.1	0.0	13.8	0.0	100.0	Merek/restoran	211	11.7%
Karbohidrat (g)	1,717	28.2	17.5	0.0	26.8	0.0	103.4	Buatan sendiri	39	2.2%
Natrium (mg)	1,229	184.7	18.0	0.0	625.7	0.0	11,998.0			

Seluruh zat gizi **menceng ke kanan** (skewness energi 0,77, lemak 2,95, natrium 10,5), sehingga median lebih representatif daripada rata-rata. Modus 0 muncul karena banyak makanan memang tidak mengandung zat tertentu (23 jenis air minum berenergi 0 kkal). Kategori energi terbanyak adalah *Sedang* (37%). Median energi produk industri (345 kkal) dan merek/restoran (298 kkal) sekitar dua kali bahan alami (144 kkal).


3. Penanganan Data

- **Nilai hilang tidak berlaku** (produsen pada bahan alami; gula, vitamin, dan mineral yang tidak dicatat sumber tertentu) tidak diimputasi; `produsen` diisi (`tanpa produsen`). **11 kolom** yang lebih dari 95% kosong dihapus. Serat/gula yang tidak tercantum dibiarkan NaN karena "tidak tercantum" belum tentu 0.
- **Missing terselubung:** 84–89% produk mencatat natrium **0 mg** (termasuk mi instan), lalu dijadikan NaN. Median natrium berubah dari 2 menjadi 18 mg/100 g.
- **Nilai tidak valid:** 69 takaran saji = 0 (mayoritas menu restoran) dijadikan NaN; 10 baris dengan nilai per 100 g mustahil (energi > 910 kkal atau makro > 105 g; maksimum awal 6.000 kkal) dijadikan NaN. Tidak ada duplikat, jumlah baris tetap 1.800.
- **Outlier statistik** (IQR: natrium 17%, lemak 7%, energi 0,6%) sebagian besar **wajar**, yaitu minyak (902 kkal), terasi/petis (hingga 11.998 mg natrium), dan whey protein, sehingga dipertahankan; analisis memakai median dan korelasi Spearman. Cek Atwater menandai 47 baris tidak konsisten, terbanyak pada data buatan sendiri (17,9%).


4. Visualisasi & Interpretasi




Gambar 1. Histogram zat gizi utama per 100 g (garis = median)



Gambar 3. Scatter lemak dan karbohidrat terhadap energi



Gambar 2. Boxplot energi per jenis sumber



Gambar 4. Correlation heatmap Spearman

- **Histogram (Gb. 1):** energi bimodal, dengan puncak 25–100 kkal (sayur, buah, minuman) dan ± 350 kkal (sereal, produk kering), plus kelompok minyak di ± 900 kkal. Lemak dan protein sangat menceng kanan (median lemak hanya 3,1 g).
- **Boxplot (Gb. 2):** produk industri dan merek/restoran jauh lebih padat energi; 39,6% produk industri berkategori energi *Tinggi* dibanding 11,1% bahan alami. Outlier bahan alami adalah minyak/lemak murni.
- **Scatter (Gb. 3):** energi naik hampir linear terhadap lemak hingga ± 900 kkal pada 100 g lemak (faktor 9 kkal/g). Terhadap karbohidrat polanya berbentuk kipas dengan batas bawah energi $\approx 4 \times$ karbohidrat.
- **Heatmap (Gb. 4):** energi paling kuat berkorelasi dengan lemak (0,73), lalu karbohidrat (0,60) dan protein (0,43); protein–lemak 0,56 (pangan hewani), karbohidrat–serat 0,47; natrium hampir independen ($|r| \leq 0,28$).

5. Kesimpulan

Dataset memenuhi ketentuan (1.800 baris, 40 kolom) dan memiliki variasi tipe atribut yang lengkap. Data TKPI berkualitas tinggi, sedangkan data kontribusi pengguna perlu dibersihkan (takaran 0, natrium 0 terselubung, energi tidak konsisten). Produk olahan terbukti jauh lebih padat energi dibanding bahan alami, dan lemak adalah penentu utama kepadatan energi. **Keterbatasan:** asumsi 1 ml $\approx$ 1 g untuk minuman, klasifikasi jenis sumber berbasis pola nama produsen, dan sampel produk hanya ID 1–1.850 dari ± 8.000 item di situs.